

Mathématiques actuarielles IARD-1  
ACT-2005  
Notes de cours

Gabriel Crépeault-Cauchon  
Nicholas Langevin

10 décembre 2018

# Table des matières

<b>I</b>	<b>Matière pour l'examen partiel</b>	<b>1</b>
<b>1</b>	<b>Quelques rappels de Probabilité</b>	<b>2</b>
1.1	Fonction de survie . . . . .	2
<b>2</b>	<b>Quantités des distributions à connaître (3)</b>	<b>4</b>
2.1	Moments . . . . .	4
2.4	Percentile . . . . .	7
2.5	Queue de distribution . . . . .	7
2.5.1	Classification selon les moments . . . . .	7
2.5.2	Classification selon les comportements limites des ailes de distribution . . . . .	7
2.5.3	Classification basée sur la fonction de Hazard . . . . .	8
2.6	Exercices recommandés . . . . .	9
<b>3</b>	<b>Fréquence et sévérité avec modifications aux contrats (8)</b>	<b>10</b>
3.2	Déductibles . . . . .	10
3.2.1	Ordinary deductible . . . . .	10
3.2.2	Franchise deductible . . . . .	12
3.3	Loss Elimination Ratio . . . . .	13
3.4	Policy Limits . . . . .	14
3.4.1	Définitions . . . . .	14
3.4.2	Fonctions reliées . . . . .	15
3.5	Coassurance, déductible et limites . . . . .	15
3.6	Exercices recommandés . . . . .	16
<b>4</b>	<b>Estimation de données complètes (11)</b>	<b>17</b>
4.2	Estimation de données complètes . . . . .	17
4.2.1	Estimation de la fonction de répartition empirique . . . . .	17

4.2.2	<i>Cumulative hazard-rate function</i> . . . . .	18
4.2.3	Notation à utiliser pour la distribution empirique . . . .	19
4.2.4	Estimateur de Nelson Åalen . . . . .	19
4.3	Distribution empirique avec données groupées . . . . .	20
4.3.1	Fonction OGIVE . . . . .	20
4.4	Exercices recommandés . . . . .	22
<b>5</b>	<b>Estimation de données modifiées (12)</b>	<b>23</b>
5.1	Point estimation . . . . .	23
5.1.1	Définitions importante . . . . .	23
5.2	Espérance, Variance et et intervalle d'estimation . . . . .	25
5.3	Exercices recommandés . . . . .	25
<b>II</b>	<b>Matière pour l'examen final</b>	<b>26</b>
<b>6</b>	<b>Continuous models (5)</b>	<b>27</b>
6.1	Multiplication par une constante . . . . .	27
6.2	Raising to a power . . . . .	28
6.3	Exponentiation . . . . .	29
6.4	Lois mélanges . . . . .	29
6.5	Frailty models . . . . .	30
6.6	Splicing . . . . .	31
6.7	Exercices recommandés . . . . .	31
<b>7</b>	<b>Modèle de perte agrégée (9)</b>	<b>32</b>
7.1	Modèle composé (fréquence-sévérité) pour les pertes agrégées	32
7.2	Exercices recommandés . . . . .	33
<b>8</b>	<b>Frequentist estimation (13)</b>	<b>34</b>
8.1	Méthode des moments . . . . .	34
8.2	Méthode des percentiles . . . . .	34
8.2.1	Smoothed empirical estimate . . . . .	35
8.3	Méthode du maximum de vraisemblance . . . . .	35
8.3.1	Données complètes . . . . .	35
8.3.2	Données groupées . . . . .	36
8.3.3	Données censurées . . . . .	37
8.3.4	Données tronquées . . . . .	37

8.4	Calcul de la variance et intervalle de confiance . . . . .	37
8.4.1	Méthode delta . . . . .	38
8.5	Likelihood Ratio Test (LRT) . . . . .	39
8.6	Exercices recommandés . . . . .	43
<b>9</b>	<b>Sélection de modèles (16)</b>	<b>44</b>
9.1	Introduction . . . . .	44
9.2	<i>Goodness-of-fit</i> Chi-Square test . . . . .	44
9.3	<i>Likelihood Ratio Test</i> (LRT) . . . . .	44
9.4	Exercices recommandés . . . . .	44
<b>10</b>	<b>Estimation Bayésienne (15)</b>	<b>45</b>
10.1	Définition de l'estimateur Bayésien . . . . .	45
10.1.1	Estimation par simulation . . . . .	46
10.2	Exercices recommandés . . . . .	49
<b>III</b>	<b>Annexes</b>	<b>50</b>
<b>A</b>	<b>Jeux de données du Loss Models</b>	<b>51</b>
A.1	Data set A . . . . .	51
A.2	Data set B . . . . .	52
A.3	Data set C . . . . .	52
A.4	Data set D1 . . . . .	53
A.5	Data set D2 . . . . .	54
<b>B</b>	<b>Rappels mathématiques</b>	<b>55</b>
B.1	Algèbre linéaire . . . . .	55

## Résumé

Ce document résume les notes de cours prises en classe dans le cours de Mathématiques actuarielles IARD-1, ainsi que des notions prises du livre *LOSS MODELS - From Data to Decisions*, 4<sup>th</sup> edition. Il est séparé en 2 parties : la matière qui a été couverte avant et après l'examen partiel.

Le chapitre correspondant dans le *Loss Models*, 4<sup>th</sup> edition est indiqué entre parenthèse des chapitres.

De plus, ce document essaie le plus possible de suivre la numérotation des sections du *Loss Models*. C'est pourquoi il arrive parfois qu'il y ait des sauts de section.

Un aide-mémoire a été créé en lien avec cette matière. Il est disponible à l'adresse suivante : [cheatsheet ACT-2005](#).

Finalement, il y a une section à la fin des chapitres qui indique les exercices recommandés dans le livre, intitulée **Exercices recommandés**.

# Première partie

Matière pour l'examen partiel

# Chapitre 1

## Quelques rappels de Probabilité

La loi gamma :

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx$$

De plus, on a

$$\Gamma(\alpha) = (\alpha - 1)\Gamma(\alpha - 1)$$

et

$$\Gamma(n) = (n - 1)!$$

### 1.1 Fonction de survie

On a

$$\begin{aligned} E[X] &= \int_{-\infty}^{\infty} x f_X(x) dx \\ &= \int_{-\infty}^{\infty} S_X(x) dx \end{aligned}$$

De plus,

$$f_X(x) = -\frac{\partial}{\partial x} S_X(x)$$

*Démonstration.*

$$\begin{aligned}f_X(x) &= -\frac{\partial}{\partial x} S_X(x) \\&= -\frac{\partial}{\partial x} (1 - F_X(x)) \\&= -(-f_X(x)) \\&= f_X(x)\end{aligned}$$

□



# Chapitre 2

## Quantités des distributions à connaître (3)

### 2.1 Moments

**Raw moments** On représente le  $k^{\text{e}}$  moment par  $\mu'_k$ , soit

$$\mu'_k = \text{E} \left[ X^k \right] \quad (2.1)$$

**Moments centraux** Le  $k^{\text{e}}$  moment central est représenté par

$$\mu_k = \text{E} \left[ (X - \mu)^k \right] \quad (2.2)$$

#### Exemple 2.1.1 Quelques exemples de moments centraux



La variance est le 2<sup>e</sup> moment central :

$$\text{Var}(X) = \mu_2 = \text{E} \left[ (X - \mu)^2 \right]$$

Le 3<sup>e</sup> moment centré, qui est utilisé pour calculer le coefficient d'asymétrie :

$$\mu_3 = \text{E} \left[ (X - \mu)^3 \right]$$


**Coefficient de variation**

$$CV = \frac{\sigma}{E[X]} \quad (2.3)$$

**Coefficient d'asymétrie** Le coefficient d'asymétrie, aussi appelé *skewness*, est défini par

$$\gamma_1 = \frac{\mu_3}{\sigma^3} \quad (2.4)$$

Soit le 3<sup>e</sup> moment standardisé. Si  $S_k = 0$ , alors la distribution tend vers une loi normale, telle qu'on le voit sur la figure ci-dessous :



**Coefficient d'applatissage** Le coefficient d'applatissage, aussi appelé *Kurtosis*, se définit par

$$\text{Kurtosis} = \frac{\mu_4}{\sigma^4} \quad (2.5)$$

Cette quantité permet de mesurer l'épaisseur de l'aile (*tail*) de la distribution. Si  $E[z^4] = 3$ , alors la distribution tend vers une loi normale  $N(\mu, \sigma^2)$ .

**Mean Excess Loss** On définit la variable aléatoire  $Y^P$ , qui représente le montant de perte en excès d'un déductible  $d$ , sachant que la perte est au delà de ce montant. On peut définir l'espérance des coûts de cette variable aléatoire :

$$e(d) = E[Y^P] = E[X - d | X \geq d] = \frac{\int_d^\infty S_X(x)}{S_X(d)} \quad (2.6)$$

Note : cette variable est dite tronquée à gauche et *shifted*. On entend parfois aussi *Per-payment*

**Left censored and shifted variable** Soit la v.a.  $Y^L$ , qui représente le montant payé par l'assureur *par perte*. La variable est donc dite *censurée à gauche et shifted*. On peut aussi en calculer l'espérance :

$$E[Y^L] = E[(X - d)_+] = \int_d^\infty (x - d)f_X(x)dx \quad (2.7)$$

De plus, on peut facilement déduire la relation suivante :

$$E[(X - d)_+] = e(d)(1 - F_X(d))$$

**Limited Loss Variable** Finalement, on peut définir la variable  $Y$ , qui représente le paiement de l'assureur avec une limite de  $u$  à la police. Son espérance est définie par

$$E[X \wedge u] = \int_0^u f_X(x)dx \quad (2.8)$$

À l'aide d'intégration par partie, on peut trouver la forme suivante :


$$E[X \wedge u] = \int_0^u S_X(x)dx$$

La v.a.  $Y$  est dite *censurée à droite et shifted*

### Exemple 2.1.2 lien entre le déductible et la limite



On peut faire le lien entre le déductible et la limite :



## 2.4 Percentile

On définit le  $p^e$  quantile (*percentile* en anglais)  $\pi_p$  comme étant la valeur minimale que  $X$  prend tel que  $F_X(\pi_p) \geq p$ .

Il arrive parfois (en contexte où  $x$  est discret) que le  $p$  percentile demandé tombe dans une *marche*. Il faut alors considérer les bornes de la fonction pour déterminer quelle valeur de  $x$  correspond au quantile demandé.

## 2.5 Queue de distribution

### 2.5.1 Classification selon les moments

- › On peut déterminer si une distribution a une *heavy-tail* en vérifiant si ses moments existent.
- › On peut aussi comparer des distributions entre-eux en utilisant des quantités standardisées, telles que le Coefficient de variation, le coefficient d'asymétrie (*skewness*) ou encore le coefficient d'aplatissement (*Kurtosis*)

### 2.5.2 Classification selon les comportements limites des ailes de distribution

- › On peut faire le ratio de deux distributions avec leurs fonction de survie ( $S(x)$ ) ou leur fonction  $f$  de densité pour vérifier laquelle des 2 a la plus grosse aile de distribution (*tail*).
1. Sois  $f_1(x)$  une fonction tels que les 3 premiers moment existe :  $E[x^4] = \infty$
  2. Sois  $f_2(x)$  une fonction tels que les 2 premiers moment existe :  $E[x^2] = \infty$

Alors,

$$\lim_{x \rightarrow \infty} r(x) = \frac{f_1(x)}{f_2(x)} = \begin{cases} \infty, & f_1(x) \text{ a une aile plus lourde que } f_2(x) \\ 0, & f_2(x) \text{ a une aile plus lourde que } f_1(x) \end{cases}$$

### Exemple 2.5.1

Sois  $f_{x_1}(x_1) \sim \text{pareto}(\alpha, \theta)$  et  $f_{x_2}(x_2) \sim \text{gamma}(\alpha, \lambda)$

$$\begin{aligned}\lim_{x \rightarrow \infty} r(x) &= \lim_{x \rightarrow \infty} \frac{f_{x_1}(x_1)}{f_{x_2}(x_2)} \\ &= \frac{\frac{\alpha \theta^\alpha}{(x+\theta)^{\alpha+1}}}{\lambda^\alpha x^{\alpha-1} e^{-\lambda x}} \\ &= C \frac{e^{-\lambda x}}{x^{\alpha-1} (x+\theta)^{\alpha+1}} \\ &= \infty\end{aligned}$$

La pareto a une queue plus lourde que la gamma

## 2.5.3 Classification basée sur la fonction de Hazard

### Définition 2.5.1 Hazard rate function



La fonction de hazard (aussi appelée force de mortalité  $(\mu(x))$  ou le failure rate  $(\lambda(x))$ ), est définie par

$$h_X(x) = \frac{f_X(x)}{S_X(x)} \quad (2.9)$$

On peut aussi exprimer la fonction  $h_X(x)$  comme

$$h_X(x) = -\ln(S_X(x))$$

Soit une distribution ayant fonction de densité  $f_X(x)$  et fonction de hazard  $h_X(x)$ . Alors,

- › Si  $h(x) \nearrow$ , *light-tailed*
- › Si  $h(x) \searrow$ , *heavy-tailed*
- › Note : on peut aussi comparer les distributions entre-elles : si une distribution voit son  $h_1(x)$  augmenter plus rapidement que l'autre (i.e.  $h_2(x)$ ), alors la deuxième distribution a une aile de distribution plus lourde.

## 2.6 Exercices recommandés

À compléter

# Chapitre 3

## Fréquence et sévérité avec modifications aux contrats (8)

### 3.2 Déductibles

#### 3.2.1 Ordinary deductible

##### Définition

Soit un contrat d'assurance avec déductible  $d$ . Lors d'une perte, l'assureur va payer tout montant en excédent du montant  $d$ . Alors, pour la variable *per-payment*,

$$Y^L = (X - d)_+ = \begin{cases} 0 & , X \leq d \\ X - d & , X > d \end{cases} \quad (3.1)$$

$$Y^P = (X - d)_+ = \begin{cases} \text{Non-défini} & , X \leq d \\ X - d & , X > d \end{cases} \quad (3.2)$$

##### Fonctions reliées

Et on peut aussi déduire toutes les fonctions qui y sont reliées :

$$f_{Y^P}(y) = \frac{f_X(y + d)}{S_X(d)}$$

$$S_{Y^P}(y) = \frac{S_X(y + d)}{S_X(d)}$$

$$F_{Y^P}(y) = \frac{F_X(y+d) - F_X(d)}{S_X(d)}$$

$$h_{Y^P}(y) = h_X(y+d)$$

Pour la v.a.  $Y^L$  *per-loss*<sup>1</sup>,

$$f_{Y^L}(y) = f_X(y+d)$$

$$S_{Y^L}(y) = S_X(y+d)$$

$$F_{Y^L}(y) = F_X(y+d)$$

## Espérance

$$E[Y^L] = E[(X-d)_+] = E[X] - E[X \wedge d] \quad (3.3)$$

$$E[Y^P] = \frac{E[(X-d)_+]}{S_X(d)} = \frac{E[X] - E[X \wedge d]}{S_X(d)} \quad (3.4)$$

Cette espérance s'appelle la prime *Stop-Loss*, et elle est définie par

$$\begin{aligned} E[Y] &= E[(X-d)_+] \\ &= \int_d^\infty (x-d)f(x)dx \\ &= \underbrace{\int_d^\infty xf(x)dx}_{\text{Intégration par partie}} - d \int_d^\infty f(x)dx \\ &= -xS(x) \Big|_d^\infty + \int_d^\infty S(x)dx - dS(d) \\ &= 0 - (-dS(d)) + \int_d^\infty S(x)dx = dS(d) + \int_d^\infty S(x)dx \\ &= \int_d^\infty S(x)dx \end{aligned}$$

---

1. Il est à noter que la fonction de Hazard n'est pas définie à 0.



### 3.2.2 Franchise deductible

#### Définitions

Lorsque la perte dépasse le deductible franchise de montant  $d$ , l'assureur assume l'entièreté des coûts<sup>2</sup>. Pour la v.a.  $Y^L$ , on a

$$Y^L = \begin{cases} 0 & , X \leq d \\ X & , X > d \end{cases}$$

Pour la v.a.  $Y^P$ ,

$$Y^P = \begin{cases} \text{non-défini} & X \leq d \\ X & , X > d \end{cases} \quad (3.5)$$

#### Fonctions reliées

Les fonctions de la v.a.  $Y^L$  sont

$$f_{Y^L}(y) = \begin{cases} F_X(d) & , y = 0 \\ f_X(y) & , y > 0 \end{cases}$$

$$F_{Y^L}(y) = \begin{cases} F_X(d) & , 0 < y \leq d \\ F_X(y) & , y \geq d \end{cases}$$

$$S_{Y^L}(y) = \begin{cases} S_X(d) & , 0 < y \leq d \\ S_X(x) & , y > d \end{cases}$$

$$h_{Y^L}(y) = \begin{cases} h_X(d) & , 0 < y \leq d \\ h_X(x) & , y > d \end{cases}$$

Pour la fonction  $Y^P$  (*per-payment*),

$$f_{Y^P}(y) = \frac{f_X(d)}{S_X(d)}$$

---

2. On voit plus souvent ce type de deductible dans un contexte d'invalidité : si on est absent plus d'un certain nombre de jours du travail, on se fait rembourser toutes ses absences en salaire.

$$F_{Y^P}(y) = \begin{cases} F_X(d) & , y = 0 \\ F_X(d) & , 0 < y \leq d \\ \frac{F_X(y) - F_X(d)}{S_X(d)} & , y > d \end{cases}$$

$$S_{Y^P}(y) = \begin{cases} 1 & , 0 \leq y \leq d \\ \frac{S_X(y)}{S_X(d)} & , y > d \end{cases}$$

$$h_{Y^P}(y) = \begin{cases} 0 & , 0 < y \leq d \\ h_X(y) & , y > d \end{cases}$$

**Espérance**

$$\mathbb{E}[Y^L] = \mathbb{E}[(X - d)_+^F] = \mathbb{E}[X] - \mathbb{E}[X \wedge d] + dS_X(d) \quad (3.6)$$

$$\mathbb{E}[Y^P] = \mathbb{E}[(X - d)_+^F] = \frac{\mathbb{E}[X] - \mathbb{E}[X \wedge d]}{S_X(d)} + d \quad (3.7)$$

### 3.3 Loss Elimination Ratio

#### Définition 3.3.1 Loss Eliminating Ratio



Le Loss Eliminating Ratio (*LER*), nous permet d'obtenir le pourcentage de perte qu'on ne paiera pas grâce au déductible  $d$  :

$$LER = \frac{\mathbb{E}[X] - \mathbb{E}[(X - d)_+]}{\mathbb{E}[X]}$$

Mais on sait que

$$\mathbb{E}[(X - d)_+] = \mathbb{E}[X] - \mathbb{E}[X \wedge d]$$

Alors,

$$LER = \frac{\mathbb{E}[X \wedge d]}{\mathbb{E}[X]} \quad (3.8)$$

**Note sur l'inflation** Il arrive en exercice qu'on nous demande de comparer ce ratio avec et sans inflation. Soit un contrat avec  $r$  % d'inflation. Alors, on peut trouver  $E[(X - d)_+]$  qui tient compte de cette inflation :

$$E[(X - d)_+] = (1 + r) \left( E[X] - E\left[X \wedge \frac{d}{1+r}\right] \right)$$

*Démonstration.*

$$E[Y] = (1 + r) \int_{\frac{d}{1+r}}^{\infty} x f_X(x) dx - d \int_{\frac{d}{1+r}}^{\infty} f_X(x) dx$$

En ajoutant un terme,

$$\begin{aligned} &= (1 + r) \underbrace{\int_0^{\frac{d}{1+r}} x f_X(x) dx}_{E[X]} + \int_{\frac{d}{1+r}}^{\infty} x f_X(x) dx - \underbrace{\int_0^{\frac{d}{1+r}} x f_X(x) dx - \frac{d}{1+r} \int_{\frac{d}{1+r}}^{\infty} f_X(x) dx}_{E\left[X \wedge \frac{d}{1+r}\right]} \\ &= E[X] - E\left[X \wedge \frac{d}{1+r}\right] \end{aligned}$$

□

## 3.4 Policy Limits

### 3.4.1 Définitions

Soit un contrat d'assurance où il est conclu que l'assureur débourse un maximum de  $u$  dans le montant de la perte. Ce type de modification au contrat crée une v.a. *censurée à droite*, i.e. le montant déboursé est maximisé à  $u$ . On définit  $Y$  comme étant

$$Y = \begin{cases} X & , X \leq u \\ u & , Y > u \end{cases} \quad (3.9)$$

### 3.4.2 Fonctions reliées

On peut déduire les fonctions reliées suivantes :

$$f_Y(y) = \begin{cases} f_X(y) & , y < u \\ S_X(u) & , y = u \end{cases}$$

$$F_Y(y) = \begin{cases} F_X(y) & , y \leq u \\ 1 & , y > u \end{cases}$$

**Note sur l'inflation** Si on a  $r$  % d'inflation, alors

$$E[X \wedge u] = (1+r)E\left[X \wedge \frac{u}{1+r}\right]$$

*Démonstration.*

$$\begin{aligned} E[Y] &= \int_0^{\frac{u}{1+r}} (1+r)x f_X(x) dx + u \int_{\frac{u}{1+r}}^{\infty} f_X(x) dx \\ &= (1+r) \int_0^{\frac{u}{1+r}} x f_X(x) dx + u S_X\left(\frac{u}{1+r}\right) \\ &= (1+r) \left( \int_0^{\frac{u}{1+r}} x f_X(x) dx + \frac{u}{1+r} S_X\left(\frac{u}{1+r}\right) \right) \\ &= (1+r)E\left[X \wedge \frac{u}{1+r}\right] \end{aligned}$$

□

## 3.5 Coassurance, déductible et limites

### Définitions

Le livre nous donne une fonction de perte qui englobe 4 éléments en même temps : l'inflation, les déductibles, la coassurance<sup>3</sup> et les limites de police.

---

3. Dans ce type de contrat, la compagnie paie une proportion  $\alpha$  de la perte, et le  $(1-\alpha)$  restant est assumé par le titulaire de la police.

Pour la v.a.  $Y^L$ ,

$$Y^L = \begin{cases} 0 & , \ x < \frac{d}{1+r} \\ \alpha \left( (1+r)x - d \right) & , \ \frac{d}{1+r} \leq x < \frac{u}{1+r} \\ \alpha(u-d) & , \ x \geq \frac{u}{1+r} \end{cases} \quad (3.10)$$

et pour  $Y^P$ ,

$$Y^L = \begin{cases} \text{Non-défini} & , \ x < \frac{d}{1+r} \\ \alpha \left( (1+r)x - d \right) & , \ \frac{d}{1+r} \leq x < \frac{u}{1+r} \\ \alpha(u-d) & , \ x \geq \frac{u}{1+r} \end{cases} \quad (3.11)$$

### Espérance

$$\mathbb{E}[Y^L] = \alpha(1+r) \left( \mathbb{E} \left[ X \wedge \frac{u}{1+r} \right] - \mathbb{E} \left[ X \wedge \frac{d}{1+r} \right] \right) \quad (3.12)$$

$$\mathbb{E}[Y^P] = \frac{\mathbb{E}[Y^L]}{S_X \left( \frac{d}{1+r} \right)} \quad (3.13)$$

$$\begin{aligned} \mathbb{E}[Y] &= \int_{\frac{d}{1+r}}^{\frac{u}{1+r}} ((1+r)x - d) f_X(x) dx + \int_{\frac{u}{1+r}}^{\infty} (u-d) f_X(x) dx \\ &= (1+r) \left( \mathbb{E} \left[ X \wedge \frac{u}{1+r} \right] - \mathbb{E} \left[ X \wedge \frac{d}{1+r} \right] \right) \end{aligned}$$

## 3.6 Exercices recommandés

À compléter

# Chapitre 4

## Estimation de données complètes (11)

### 4.2 Estimation de données complètes

#### 4.2.1 Estimation de la fonction de répartition empirique


On cherche à estimer  $F(t)$  ou  $S(t)$ , lorsque nos données sont complètes (i.e.  $x_1, \dots, x_n$  qui sont *iid*). Alors, l'estimateur non paramétrique pour  $F(t)$  :

$$F_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{x_i \leq t\}} \quad (4.1)$$

où  $\mathbb{1}_{\{.\}}$  représente une fonction indicatrice.  
 $F_x(t)$  aura donc la forme suivante :

$$F_n(t) = \begin{cases} 0 & , t < x_{(1)} \\ \frac{1}{n} & , x_{(1)} \leq t < x_{(2)} \\ \frac{2}{n} & , x_{(2)} \leq t < x_{(3)} \\ \dots & \\ 1 & , t \geq x_{(n)} \end{cases} \quad (4.2)$$

où  $t \in [0, x_{(n)}]$ .



### Remarques

- (1) Lorsque  $F_n(t) \rightarrow F(t)$ , alors
- (2) Puisqu'on a

$$\sum_{i=1}^n 1_{[x_i \leq t]} \sim \text{Bin}(n, \Pr(X \leq t))$$

Alors,

$$\begin{aligned} E[F_n(t)] &= \frac{1}{n} n F(t) \\ &= F(t) \quad (\text{C'est un estimateur sans biais}) \\ \text{Var}(F_n(t)) &= \frac{1}{n^2} n F(t) S(t) \\ &= \frac{F(t) S(t)}{n} \\ &\underset{n \rightarrow \infty}{=} 0 \end{aligned}$$

### 4.2.2 Cumulative hazard-rate function

On utilise cette fonction pour pouvoir réussir à estimer la fonction de densité et le *hazard rate* empirique. En effet, puisque la distribution empirique est

discrète, on ne peut pas dériver  $F_n(x)$  pour obtenir  $f_n(x)$  et  $h_n(x)$ . La fonction de hazard cumulative se définit par

$$H_X(x) = -\ln S_X(x) \quad (4.3)$$

### 4.2.3 Notation à utiliser pour la distribution empirique

- ›  $y_1 < y_2 < \dots < y_k$  : les  $k$  valeurs uniques qui apparaissent dans l'échantillon de  $n$ . **Note :**  $k \leq n$ .
- ›  $s_j$  : nombre de fois que l'observation  $y_j$  est observée dans l'échantillon. On a

$$\sum_{j=1}^k s_j = 1$$

- ›  $r_j$  : nombre d'observations qui sont plus grandes ou égales à  $y_j$ . On a

$$r_j = \sum_{i=j}^k s_i$$

- › Avec cette nouvelle notation, on peut ré-écrire la fonction de répartition empirique :

$$F_n(x) = \begin{cases} 0 & , x < y_1 \\ 1 - \frac{r_j}{n} & , y_{j-1} \leq x \leq y_j \quad j = 2, \dots, k \\ 1 & , x \geq y_k \end{cases} \quad (4.4)$$

### 4.2.4 Estimateur de Nelson Åalen

Pour pouvoir estimer la *Cumulative hazard-rate function*, on doit utiliser un estimateur qui se base sur la notation utilisée à la sous-section précédente, soit le *Nelson Åalen estimate* :

$$\hat{H}(x) = \begin{cases} 0 & , x < y_1 \\ \sum_{i=1}^{j-1} \frac{s_i}{r_i} & , y_{j-1} \leq x \leq y_j \quad j = 2, \dots, k \\ \sum_{i=1}^k \frac{s_i}{r_i} & , x \geq y_k \end{cases} \quad (4.5)$$



## 4.3 Distribution empirique avec données groupées

### 4.3.1 Fonction OGIVE

**CETTE MATIÈRE NE SERA PAS TESTÉE À L'EXAMEN intra A2018**

Dans certains contextes, on a  $n$  données qui sont groupées en intervalles. La fonction OGIVE permet d'interpoler entre 2 points  $c_{j-1}$  et  $c_j$ .

$$\begin{aligned} c_{j-1} &\leq x \leq c_j \\ F_n(c_{j-1}) &\leq F_n(x) \leq F_n(c_j) \end{aligned}$$

On peut déterminer la valeur empirique de  $F_n(x)$  aux bornes des classes, avec

$$F_n(x) = \frac{\sum_{i=1}^j n_i}{n}$$

où  $n_i$  est le nombre d'observations qui sont entre  $c_{j-1}$  et  $c_j$ . Toutefois, pour les valeurs entre deux bornes  $c_0 < c_1 < \dots < c_k$ , il faut approximer avec la fonction OGIVE ci-dessous :

$$F_n^{\text{OGIVE}}(x) = \frac{c_j - x}{c_j - c_{j-1}} F_n(c_{j-1}) + \frac{x - c_{j-1}}{c_j - c_{j-1}} F_n(c_j) \quad (4.6)$$

#### Remarques

(1) Si  $x = c_{j-1}$ ,

$$F_n(c_{j-1}) = F_n^{\text{OGIVE}}(c_{j-1})$$

(2) Si  $x = c_j$ ,

$$F_n(c_j) = F_n^{\text{OGIVE}}(c_j)$$

(3) En dérivant (4.6), on obtient

$$\begin{aligned} f_n(x) &= \frac{\partial}{\partial x} F_x(x) \\ &= \frac{1}{c_j - c_{j-1}} F_x(c_j) - \frac{1}{c_j - c_{j-1}} F_n(c_{j-1}) \\ &= \frac{F_n(c_j) - F_n(c_{j-1})}{c_j - c_{j-1}} \end{aligned} \tag{4.7}$$

#### Exemple 4.3.1 Fonction R ogive



Du package [actuar](#), on peut utiliser la fonction `ogive()` pour calculer les probabilités empiriques à des points précis de nos données lorsqu'elles sont groupées, mais aussi interpoler entre 2 valeurs :

```
## Fonction OGIVE du package actuar de Vincent Goulet
## Exemple numéro 5.2 du Loss Models
## page 68, 4e édition
library(actuar)


## On définit le vecteur cj des bornes et
## un vecteur nj des fréquences empiriques
# note : il faut forcer une borne supérieure
cj <- c(0, 300, 350, 400, 450, 500, 600, 2000)
nj <- c(42, 3, 5, 5, 0, 5, 40)

# On calcule la fonction ogive avec la fonction du même nom
Fn <- ogive(cj, nj)

y <- 500 / (1.1)^3
# On calcule la probabilité demandée
1 - Fn(y)
[1] 0.5243426

# On peut aussi faire un graphique de la
## fonction empirique OGIVE
plot(Fn)
```

Et on obtient le graphique suivant :



## 4.4 Exercices recommandés

À compléter

# Chapitre 5

## Estimation de données modifiées (12)

### 5.1 Point estimation

#### 5.1.1 Définitions importante

Un vocabulaire spécifique aux données modifiées est utilisé, soit

Définition	Terme anglais	Explication
Tronquée à gauche	<i>left truncated at d</i>	si la valeur observée est plus basse que $d$ , elle n'est pas enregistrée
Tronquée à droite	<i>right truncated at u</i>	si la valeur observée est plus grande que $u$ , elle n'est pas enregistrée
Censurée à gauche	<i>left censored at d</i>	si la valeur observée est plus basse que $d$ , on indique $d$ dans les données modifiées
Censurée à droite	<i>right censored at u</i>	si la valeur observée est plus grande que $u$ , on indique $u$ dans les données modifiées

**Note** : Il arrive aussi que les données soient *shifted at d*, ce qui veut dire qu'on soustrait  $d$  aux données (souvent en présence d'un déductible).

### Notation

- >  $y_1 < y_2 < \dots < y_k$  : les  $k$  valeurs uniques qui apparaissent dans l'échantillon.
- >  $x_j$  : la  $j^{\text{e}}$  données non-censurée qui apparaît dans l'échantillon
- >  $d_j$  : le montant auquel  $x_j$  est tronquée. Si il n'y a pas de troncage, alors  $d_j = 0$ .
- >  $u_j$  : la  $j^{\text{e}}$  données censurée qui apparaît dans l'échantillon.
- >  $r_j$  : nombre d'observations qui sont plus grandes ou égales à  $y_j$  (*risk set*)

$$r_j = \# \text{ of } x_i + \# \text{ of } u_i - (\# \text{ of } d_i \geq y_j)$$

›  $s_i$  : nombre de décès au temps  $i$ .

### Estimateur de Kaplan-Meier

Cet estimateur est une version modifiée de l'estimateur de Nelson-Åalen vu à la section 4.2.4. Avec l'information des données et en utilisant la notation vue à la sous-section précédente, on peut estimer la fonction de survie empirique :

$$\hat{S}_n(t) = \begin{cases} 1 & , 0 \leq t < y_1 \\ \prod_{i=1}^{j-1} \left( \frac{r_i - s_i}{r_i} \right) & , y_{j-1} \leq t < y_j \quad j = 2, \dots, k \\ \prod_{i=1}^k \left( \frac{r_i - s_i}{r_i} \right) & t \geq y_k \end{cases} \quad (5.1)$$

## 5.2 Espérance, Variance et intervalle d'estimation

### Contexte

On s'intéresse à l'espérance et la variance de la fonction de survie  $S_n$ , qui suite une binomiale (i.e.  $S_n(x) \sim \text{Bin}(n, S(x))$ ). Si on connaissait  $S(x)$ , on pourrait facilement déduire l'espérance et la variance avec les formules qu'on connaît. Toutefois, puisqu'on cherche souvent à estimer  $S(x)$ , il faudra aussi estimer l'espérance et la variance.

Section à compléter

## 5.3 Exercices recommandés

À compléter

**Deuxième partie**

**Matière pour l'examen final**

# Chapitre 6

## Continuous models (5)

### 6.1 Multiplication par une constante

Soit  $X$  la v.a. représentant les pertes et  $\theta$  un paramètre d'échelle (*scale parameter*). On peut définir la v.a.  $Y$  par

$$Y = \theta X$$

Alors,

$$\begin{aligned} F_Y(y) &= \Pr(Y \leq y) \\ &= \Pr(\theta X \leq y) \\ &= \Pr\left(X \leq \frac{y}{\theta}\right) \\ &= F_X\left(\frac{y}{\theta}\right) \end{aligned} \tag{6.1}$$

Et on peut aussi trouver que

$$\begin{aligned} f_Y(y) &= \frac{\partial}{\partial y} F_Y(y) \\ &= \frac{\partial}{\partial y} \left\{ F_X\left(\frac{y}{\theta}\right) \right\} \\ &= \frac{1}{\theta} f_X\left(\frac{y}{\theta}\right) \end{aligned} \tag{6.2}$$



**À noter** Si on doit appliquer une transformation impliquant une puissance (*raising to a power*, voir section [section 6.2](#)), on applique cette dernière transformation avant d'appliquer le paramètre d'échelle  $\theta$ .

## 6.2 Raising to a power

Soit  $X$  une v.a. représentant la perte avec une loi de probabilité quelconque et la v.a.  $Y$  tel que

$$Y = X^{\frac{1}{\tau}}$$

avec  $\tau > 0$ . On peut trouver  $F_Y(y)$  ainsi que  $f_Y(y)$  :

$$\begin{aligned} F_Y(y) &= \Pr(Y \leq y) \\ &= \Pr\left(X^{\frac{1}{\tau}} \leq y\right) \\ &= \Pr(X \leq y^\tau) \\ &= F_X(y^\tau) \end{aligned} \tag{6.3}$$

et

$$\begin{aligned} f_Y(y) &= \frac{\partial}{\partial y} F_Y(y) \\ &= \frac{\partial}{\partial y} F_X(y^\tau) \tau y^{\tau-1} f_X(y^\tau) \end{aligned} \tag{6.4}$$

**Note** On préfère toujours des paramètres positifs, donc on va ajuster les formules avec des constantes négatives dans certains cas.

### Exemple 6.2.1 Notation dans le livre *Loss Models*



La notation utilisée par le livre est la suivante :

- › si  $\tau > 0$  : *transformed*
- › si  $\tau = -1$  : *inverse*
- › si  $\tau < 0$  et  $\tau \neq -1$  : *inverse-transformed*

## 6.3 Exponentiation

Soit  $X$  une v.a. représentant la perte. On définit  $Y$  comme

$$Y = \exp(X)$$

Alors, on trouve

$$\begin{aligned} F_Y(y) &= \Pr(Y \leq y) \\ &= \Pr(e^X \leq y) \\ &= \Pr(X \leq \ln y) \\ &= F_x(\ln y) \end{aligned} \tag{6.5}$$

et

$$\begin{aligned} f_Y(y) &= \frac{\partial}{\partial y} F_Y(y) \\ &= \frac{\partial}{\partial y} \{F_x(\ln y)\} \\ &= \frac{1}{y} f_x(\ln y) \end{aligned} \tag{6.6}$$

**Note** La loi Log-Normale est en fait une transformation exponentielle de la Loi Normale.

## 6.4 Loix mélanges

On peut créer des loix mélanges. En effet, il arrive qu'on ait une distribution dont l'un des paramètres est lui-même distribué aléatoirement selon une autre distribution, tel que

$$X|\Lambda \sim \text{une certaine loi}$$

$$\Lambda \sim \text{une autre loi (ou la même!)}$$

On peut trouver les fonctions de densité et de répartition de ces différentes loix :

$$f_X(x) = \int_{-\infty}^{\infty} f_{X|\Lambda}(x|\lambda) f_{\Lambda}(\lambda) d\lambda \tag{6.7}$$

$$F_X(x) = \int_{-\infty}^{\infty} F_{X|\Lambda}(x|\lambda) f_{\Lambda}(\lambda) d\lambda \quad (6.8)$$

De plus, on peut trouver l'espérance et la variance de ces lois mélanges avec les théorèmes de l'espérance et la variance conditionnelle :

$$E[X] = E[E[X|\Lambda]] \quad (6.9)$$

$$Var(X) = E[Var(X|\Lambda)] + Var(E[X|\Lambda]) \quad (6.10)$$

## 6.5 Frailty models

Est sur le syllabus des examens professionnels, mais ne semble pas être à l'étude pour le cours IARD1 ...

Soit un paramètre  $\Lambda > 0$  (*frailty random variable*) qu'on va utiliser pour trouver la *hazard-rate* conditionnel  $h_{X|\Lambda}$  tel que

$$h_{X|\Lambda}(x|\lambda) = \lambda a(x) \quad (6.11)$$

où  $a(x)$  est une fonction quelconque et la distribution de  $\Lambda = \lambda$  est connu. Alors, on peut trouver la fonction de survie de  $S_{X|\Lambda}(x|\lambda)$  avec des des propriétés que l'on connaît :

$$\begin{aligned} S_{X|\Lambda}(x|\lambda) &= e^{-\int_0^x h_{X|\Lambda}(t|\lambda) dt} \\ &= e^{-\lambda A(x)} \\ &= M_{\Lambda}(-A(x)) \\ &= \mathcal{L}_{\Lambda}(A(x)) \end{aligned}$$

## 6.6 Splicing

Soit  $X_1, \dots, X_k$  les différentes distributions que peut prendre la v.a.  $X$  et  $\alpha_i$  la probabilité que  $X \sim X_i$ ,  $i = 1, 2, \dots, k$ . Pour  $\sum \alpha_i = 1$ , on a donc

$$f_X(x) = \begin{cases} \alpha_1 f_1(x) & , c_0 < x < c_1 \\ \alpha_2 f_2(x) & , c_2 < x < c_2 \\ \dots & \\ \alpha_k f_1(k) & , c_{k-1} < x < c_k \end{cases}$$

**Note** Dans un problème, on peut soit demander de calculer la fonction de répartition à un certain point, ou encore nous demander de trouver les coefficients  $\alpha_i$  en connaissant les différentes fonctions de répartition et les probabilités rattachées.

## 6.7 Exercices recommandés

Les exercices recommandés dans le *Loss Models*, 4<sup>th</sup> edition pour ce chapitre sont les suivants :

- > 5.1 à 5.6
- > 5.8 à 5.11
- > 5.17 à 5.19

# Chapitre 7

## Modèle de perte agrégée (9)

### 7.1 Modèle composé (fréquence-sévérité) pour les pertes agrégées

On définit les variables aléatoires suivantes :

- ›  $S$  : Perte totale pour le portefeuille au complet ;
- ›  $N$  : Nombre de réclamations observées dans l'intervalle de temps. (**fréquence**) ;
- ›  $X_1, \dots, X_n$  : Montant de perte relié à la  $i^{\text{e}}$  réclamation (**sévérité**).<sup>1</sup>

On a donc

$$S = X_1 + \dots + X_n$$

et on peut trouver diverses quantités, tel que la fonction de répartition :

$$F_S(x) = \sum_{n=0}^{\infty} F_X^{*n}(x) \Pr(N = n) \quad (7.1)$$

où  $F_X^{*n} = \Pr(X_1 + \dots + X_n \leq x)$ .

On peut aussi obtenir la fonction génératrice des moments :

$$\mathcal{M}_S(t) = \mathcal{P}_N(\mathcal{M}_X(t)) \quad (7.2)$$

---

1. Les  $X_i$  sont iid et indépendants de  $N$ .

L'espérance et la variance peuvent être obtenues avec les propriétés d'espérance et variance conditionnelle :

$$\begin{aligned}
 E[S] &= E[E[S|N]] \\
 &= E\left[E\left[\sum_{i=1}^n X_i\right]\right] \\
 &= E\left[\sum_{i=1}^n E[X_i]\right] \\
 &\stackrel{iid}{=} E[NE[X]] \\
 &= E[N] E[X]
 \end{aligned}
 \tag{7.3}$$

$$\begin{aligned}
 \text{Var}(S) &= \text{Var}(E[S|N]) + E[\text{Var}(S|N)] \\
 &= \text{Var}\left(E\left[\sum_{i=1}^n X_i\right]\right) + E\left[\text{Var}\left(\sum_{i=1}^n X_i\right)\right] \\
 &= \text{Var}\left(\sum_{i=1}^n E[X_i]\right) + E\left[\sum_{i=1}^n \text{Var}(X_i)\right] \quad , \text{ par indépendance des } X_i \\
 &\stackrel{iid}{=} \text{Var}(NE[X]) + E[N\text{Var}(X)] \\
 &= E[X]^2 \text{Var}(N) + E[N] \text{Var}(X)
 \end{aligned}
 \tag{7.4}$$

## 7.2 Exercices recommandés

Les exercices recommandés dans le *Loss Models, 4<sup>th</sup> edition* pour ce chapitre sont les suivants :

➤ 9.34 et 9.36

# Chapitre 8

## Frequentist estimation (13)

### 8.1 Méthode des moments

On cherche à estimer les paramètres de la distribution de nos données, sachant que la distribution suit une loi quelconque.

Si on a  $p$  paramètres à estimer, alors il faudra calculer les  $p$  premiers moments empiriques de la distribution, soit

$$\hat{\mu}'_k = \sum_{i=1}^n x_i^k \quad (8.1)$$

Puis d'utiliser cette quantité empirique pour résoudre le système d'équation à  $p$  inconnus tel que  $\hat{\mu}'_k = \mu'_k$ .

### 8.2 Méthode des percentiles

Pour un rappel sur les percentiles, voir la [section 2.4](#). Cette méthode est appelée en anglais *percentile matching estimate*.

Un peu comme la méthode des moments, on utilise une quantité qu'on peut calculer empiriquement, soit la fonction de répartition empirique, pour pouvoir résoudre le système d'équations à  $p$  variables tel que

$$F_n(\hat{\pi}_{g_i}) = g_i$$

où

- ›  $\hat{\pi}_{g_i} = F_n^{-1}(g_i)$ ,  $i = 1, \dots, p$
- ›  $F_n$  : la fonction de répartition empirique <sup>1</sup>
- ›  $p$  : nombre de paramètres de la distribution à estimer.

### 8.2.1 Smoothed empirical estimate

Il arrive parfois que le percentile arrive entre 2 *marche* de la fonction de répartition empirique. Dans cette situation,  $\hat{\pi}_g$  doit être approximé de façon linéaire avec les statistiques d'ordre :

$$\hat{\pi}_g = (1 - h)X_{(j)} + hX_{(j+1)} \quad (8.2)$$

où

- ›  $j = \lfloor (n + 1)g \rfloor$  et  $h = (n + 1)g - j$
- ›  $X_{(j)}$  la  $j^{\text{e}}$  statistique d'ordre de l'échantillon empirique  $X$ .

## 8.3 Méthode du maximum de vraisemblance

### 8.3.1 Données complètes

aussi appelé *Maximum log-likelihood estimator (MLE)*. On cherche à estimer le paramètre  $\hat{\theta}$  en maximisant la fonction de vraisemblance <sup>2</sup>.

#### Définition 8.3.1 Fonction de vraisemblance



La fonction de vraisemblance  $L(\theta|x)$  est la probabilité d'obtenir un échantillon  $x_1, \dots, x_n$  d'une distribution  $f_X(x)$  ayant le vecteur de paramètres  $\theta$ . Alors,

$$L(\theta) = \prod_{i=1}^n f_X(x_i; \theta) \quad (8.3)$$

On peut aussi trouver la fonction de log-vraisemblance  $\ell(\theta)$  (qui est souvent plus facile à dériver) :

$$\ell(\theta) = \sum_{i=1}^n \ln f_X(x_i; \theta) \quad (8.4)$$

1. L'estimation de la fonction de répartition empirique est couvert au [chapitre 4](#).
2. Il arrive parfois que la seule façon de trouver le paramètre qui maximise  $L(\theta)$  est en utilisant des [méthodes numériques](#)



**Estimation du paramètre  $\theta$**  On détermine l'estimateur du maximum de vraisemblance (*MLE* en anglais)<sup>3</sup> tel qu'on maximise l'Équation 8.3. Intuitivement, on va donc trouver le paramètre  $\theta$  tel que

$$\frac{\partial}{\partial \theta} L(\theta) = 0$$

Puisque la fonction de vraisemblance peut parfois être difficile à dériver, on utilise souvent la fonction de log-vraisemblance (Équation 8.4) :

$$\frac{\partial}{\partial \theta} \ell(\theta) = 0$$

**Estimation du vecteur de paramètres  $\theta$**  Si on doit estimer plusieurs paramètres  $\theta_i$  pour la fonction  $f_X$ , on procède de la même façon, en dérivant partiellement la fonction de vraisemblance (ou log-vraisemblance) par rapport à chacun des paramètres  $\theta_i$  et en posant ces dérivées égales à 0.

### 8.3.2 Données groupées

Lorsque les données sont groupées dans les intervalles  $c_0 < c_1 < \dots < c_k$ , la fonction de vraisemblance  $L(\theta)$  est différente.  $X \sim \text{Multinomiale}(\mathbf{n}, \mathbf{p})$ . Alors,

$$L(\theta) = \Pr(n_1, n_2, \dots, n_k; \theta) = \binom{n}{n_1, \dots, n_k} p_1^{n_1} \dots p_k^{n_k} \quad (8.5)$$

Dans le contexte de données groupées, on a que  $p_j = \Pr(X_j \in (c_{j-1}, c_j))$ . Donc, la fonction de vraisemblance est

$$L(\theta) = \prod_{j=1}^n (F_X(c_j | \theta) - F_X(c_{j-1} | \theta))^{n_j}$$

Et la fonction de log-vraisemblance (en enlevant la constante combinatoire) est donc

$$\ell(\theta) = \sum_{j=1}^k n_j \ln (F_X(c_j; \theta) - F_X(c_{j-1}; \theta)) \quad (8.6)$$

---

3. L'abréviation en français est EMV, mais on utilise surtout *MLE* pour Maximum likelihood estimator.

### 8.3.3 Données censurées

Si une donnée est censurée, on l'interprète comme une donnée groupée dont l'intervalle va jusqu'à  $\infty$ . On remplace  $f_X(x_j)$  par  $1 - F_X(x_j)$ .

### 8.3.4 Données tronquées

Si une donnée est tronquée, on a 2 options :

1. On soustrait de chacune des observations le point de troncation  $d$  ;
2. (**Méthode plus souvent utilisée**) : On conditionne pour que les données sous le point de troncation  $d$  ne soient pas considérées, i.e. on remplace  $f(x_j|\theta)$  par  $\frac{f(x_j|\theta)}{1-F(d)}$ .

## 8.4 Calcul de la variance et intervalle de confiance

L'explication donnée ici est reprise de l'ouvrage *Modélisation des sinistres avec R*<sup>4</sup>.

Lorsque  $n \rightarrow \infty$ , on sait que le vecteur de paramètres  $\hat{\theta} \sim N(\theta, \text{Var}(\hat{\theta}))$ , avec  $\text{Var}(\hat{\theta}) = I(\theta)^{-1}$ <sup>5</sup>.

#### Définition 8.4.1 Information de Fisher



La matrice d'information de Fisher est définie par

$$I(\theta) = -n\mathbb{E} \left[ \frac{\partial^2}{\partial \theta^2} \ln f_X(x; \theta) \right] = n\mathbb{E} \left[ \left( \frac{\partial}{\partial \theta} \ln f_X(x; \theta) \right)^2 \right] \quad (8.7)$$

La première version étant seulement applicable dans le cas où toutes les variables et observations sont *iid*, on utilise plus souvent la version généralisée :

$$I(\theta) = -\mathbb{E} \left[ \frac{\partial^2}{\partial \theta^2} \ell(\theta) \right] = \mathbb{E} \left[ \left( \frac{\partial}{\partial \theta} \ell(\theta) \right)^2 \right] \quad (8.8)$$

Il arrive qu'on remplace l'espérance par *l'observation observée* dans les équations ci-dessus, lorsqu'elle est trop compliquée à calculer. On

4. [Ouvrage de Vincent Goulet](#), section 5.5 (page 203 à 212)

5. Pour un rappel sur les matrices inverses, voir l'annexe [B.1](#).

définit *l'information observée* telle que

$$\hat{I}(\hat{\theta}) = \sum_{i=1}^n \left( \frac{\partial}{\partial \theta} \ln f(x_i; \theta) \Big|_{\theta=\hat{\theta}} \right)^2 = - \sum_{i=1}^n \frac{\partial^2}{\partial \theta^2} \ln f(x_i; \theta) \Big|_{\theta=\hat{\theta}} \quad (8.9)$$

Donc, on peut calculer un intervalle de confiance (bilatéral) au seuil  $1 - \alpha$  autour de  $\theta$  :

$$\begin{aligned} \Pr \left( -z_{\alpha/2} < \frac{\hat{\theta} - \theta}{\sqrt{\text{Var}(\hat{\theta})}} < z_{\alpha/2} \right) &= 1 - \alpha \\ \Pr \left( \hat{\theta} - z_{\alpha/2} \sqrt{\text{Var}(\hat{\theta})}, \hat{\theta} + z_{\alpha/2} \sqrt{\text{Var}(\hat{\theta})} \right) &= 1 - \alpha \end{aligned}$$

D'où l'IC au seuil  $1 - \alpha$  est

$$\theta \in \left[ \hat{\theta} \pm z_{\alpha/2} \sqrt{\text{Var}(\hat{\theta})} \right] \quad (8.10)$$

### 8.4.1 Méthode delta

Dans certains cas, on désire approximer une autre quantité que le paramètre lui-même, qui est en fait une transformation  $h(\theta)$  de ce dernier. On doit utiliser la méthode Delta, qui fait une approximation de Taylor de premier ordre sur la fonction  $h(\theta)$ . Alors, on a que

$$h(\hat{\theta}) \approx h(\theta) + \frac{\partial}{\partial \theta} h(\theta)(\hat{\theta} - \theta)$$

On a que

$$\mathbb{E} [h(\hat{\theta})] = h(\hat{\theta})$$

et

$$\begin{aligned} \text{Var}(\hat{\theta}) &= \text{Var} \left( h(\theta) + \frac{\partial}{\partial \theta} h(\theta)(\hat{\theta} - \theta) \right) \\ &= \left( \frac{\partial}{\partial \theta} h(\theta) \right)^2 \text{Var}(\hat{\theta}) \end{aligned}$$

Dans un contexte multivarié (où il faut estimer plus d'un paramètre), on a

$$\text{Var} \left( h(\hat{\theta}) \right) = \mathbf{h}^\top I(\theta)^{-1} \mathbf{h}$$

où  $\mathbf{h}$  est le vecteur des dérivées partielles de  $h(\theta)$  :

$$\mathbf{h} = \begin{bmatrix} \frac{\partial}{\partial \theta_1} h(\theta) \\ \frac{\partial}{\partial \theta_2} h(\theta) \\ \dots \\ \frac{\partial}{\partial \theta_k} h(\theta) \end{bmatrix}$$

## 8.5 Likelihood Ratio Test (LRT)

Le test du rapport de vraisemblance (*Likelihood ratio test*) permet de valider si la fonction de vraisemblance d'un modèle avec paramètres *constraints* est proche de la fonction de vraisemblance maximisée lorsqu'il n'y a aucune contrainte sur les paramètres. Ce test a plusieurs applications, notamment ici et dans l'ajustement de modèles linéaires généralisés. Une application directe dans la [section 9.3](#) est présentée. En résumé, on la mesure statistique du test est la suivante :

$$\lambda = \frac{L(\hat{\theta}_0)}{L(\hat{\theta})}$$

où

- ›  $L(\theta_0)$  représente la fonction de vraisemblance du modèle avec paramètres contraints ;
- ›  $\ell(\theta)$  représente la fonction de vraisemblance pour le modèle complet.

On peut prouver que

$$-2 \ln \lambda \sim \chi_{dl_1 - dl_0}^2 \quad (8.11)$$

où

- ›  $dl_1$  représente le nombre de degrés de libertés du modèle complet (i.e. le nombre de paramètres qu'on peut modifier, qui ne sont pas fixés)
- ›  $dl_0$  le nombre de paramètres non fixés du modèle avec paramètres contraints à tester

où et .

Dans le contexte d'estimation de paramètres, on aura le modèle complet qui correspond en fait

Souvent, l'Équation 8.11 est plutôt présentée comme

$$2(\ell(\theta) - \ell(\theta_0)) \sim \chi_{dl_1 - dl_0}^2 \quad (8.12)$$

**Le test LRT** le ratio  $\lambda$  sera toujours  $\leq 1$ , car le modèle avec paramètres estimés ne peut pas estimer parfaitement la distribution. Toutefois, on veut que la différence entre la logvraisemblance de la distribution ( $\ell(\theta)$ ) et celle du modèle avec paramètres estimés ( $\ell(\theta_0)$ ) ne soit pas significativement trop élevée<sup>6</sup>, i.e.

$$2(\ell(\theta) - \ell(\theta_0)) \leq \chi_{dl_1 - dl_0, 1-\alpha}^2 \quad (8.13)$$

**Construction d'un intervalle de confiance** Comme n'importe quel test d'hypothèse, il est possible avec le LRT de construire un intervalle de confiance autour de nos paramètres estimés en *inversant* le test. En effet,  $\hat{\theta}_0$  doit être le paramètre qui respecte l'Équation 8.13 à un seuil  $1 - \alpha$ .

#### Exemple 8.5.1 Exemple avec Q13.57 du Loss Models



**13.57** The following 20 observations were collected. It is desired to estimate  $\Pr(X > 200)$ . When a parametric model is called for, use the single-parameter Pareto distribution for which  $F(x) = 1 - (100/x)^\alpha$ ,  $x > 100$ ,  $\alpha > 0$ .

132	149	476	147	135	110	176	107	147	165
135	117	110	111	226	108	102	108	227	102

On sait que  $\hat{\alpha} = 2,848$  et  $\hat{\theta} = 100$ .

Trouver l'intervalle de confiance à 95% en inversant le test du ratio de vraisemblance (LRT).

6. Autrement dit, on va rejeter  $H_0$  que le modèle avec les paramètres estimés est adéquat si la statistique  $\lambda$  dépasse le quantile  $\chi^2$ .

(1) On peut trouver que la fonction de densité est

$$\begin{aligned} f(x; \alpha) &= \frac{\partial}{\partial \alpha} F(x; \alpha) \\ &= \frac{\partial}{\partial \alpha} \left( 1 - \left( \frac{100}{x} \right)^\alpha \right) \\ &= \frac{\alpha 100^\alpha}{x^{\alpha+1}} \end{aligned}$$

(2) Les fonctions de vraisemblance  $L$  et log-vraisemblance  $\ell$  sont, respectivement

$$\begin{aligned} L(\alpha) &= \prod_{i=1}^{20} f(x_i; \alpha) \\ &= \prod_{i=1}^{20} \frac{\alpha 100^\alpha}{x_i^{\alpha+1}} \end{aligned}$$

et

$$\begin{aligned} \ell(\alpha) &= \ln L(\alpha) \\ &= \sum_{i=1}^{20} \ln(\alpha) + \alpha \ln(100) - (\alpha + 1) \ln(x_i) \\ &= 20 \ln(\alpha) + 20\alpha \ln(100) - (\alpha + 1) \sum_{i=1}^{20} \ln(x_i) \end{aligned}$$

Avec la fonction **DATA** de la calculatrice TI-30XS, on peut facilement calculer le terme  $\sum_{i=1}^{20} \ln x_i = 99,125$ . En remplaçant  $\alpha$  par  $\hat{\alpha} = 2,848$ , on obtient donc


$$\ell(\alpha) = -98,190166$$

(3) On peut trouver  $\hat{\alpha}_0$  qui résoud

$$\begin{aligned}
 2(\ell(\hat{\alpha}) - \ell(\hat{\alpha}_0)) &\leq \chi_{1,0.95}^2 \\
 2(-98,190166 - (20 \ln(\hat{\alpha}_0) + \\
 20\hat{\alpha}_0 \ln(100) - (\hat{\alpha}_0 + 1)99,125) &\leq 3,841 \\
 -196,38033 - 40 \ln \hat{\alpha}_0 - 40\hat{\alpha}_0 \ln 100 + 198,25(\hat{\alpha}_0 + 1) &\leq 3,841 \\
 -200,2213 - 40 \ln \hat{\alpha}_0 - 40\hat{\alpha}_0 \ln 100 + 198,25(\hat{\alpha}_0 + 1) &\leq 0
 \end{aligned}$$

Avec la fonction **TABLE** de la calculatrice TI-30XS, on peut entrer cette fonction, et tester pour des valeurs de  $\hat{\alpha}_0$  jusqu'à résolution. On doit obtenir une borne  $L < \hat{\alpha}$  et une borne  $U > \hat{\alpha}$ .

(4) Graphiquement,



(5) Alors,

$$\alpha \in [1,77; 4,28]$$

## 8.6 Exercices recommandés

Les exercices recommandés dans le *Loss Models*, 4<sup>th</sup> edition pour ce chapitre sont les suivants :

- › Méthode des moments et percentiles : 13.1 à 13.22
- › *MLE* : 13.30, 13.32, 13.33, 13.37, 13.38 à 13.40, 13.45 à 13.51 et 13.54 à 13.57
- › Variance et intervalle de confiance : 13.62 à 13.72
- › Non-normal confidence interval : 13.74



# Chapitre 9

## Sélection de modèles (16)

### 9.1 Introduction

Il existe plusieurs tests (graphiques, tests d'hypothèses, etc.) pour valider si un modèle est adéquat. Les 2 tests vus dans le cadre du cours sont le  
Souvent, certaines valeurs de ces tests peuvent aussi être utilisé pour comparer différents modèles entre-eux.

### 9.2 *Goodness-of-fit* Chi-Square test

### 9.3 *Likelihood Ratio Test* (LRT)

### 9.4 Exercices recommandés

Test Kolmogorov-Smirnov 16.4 et 16.5<sup>1</sup>

Goodness-of-fit test et LRT 16.10 à 16.15

Critères de sélection 16.23 et 16.24

---

1. Cette matière n'est pas testée à l'examen final A2018 en IARD1.

# Chapitre 10

## Estimation Bayésienne (15)

### 10.1 Définition de l'estimateur Bayésien

#### Définition 10.1.1 Distribution *a priori*



Soit un paramètre  $\theta$  d'une distribution quelconque. Afin de réaliser une estimation Bayésienne, on connaît *a priori* la distribution que prend le paramètre  $\theta$ , qu'on dénote par  $\pi(\theta)$ .

Alors, notre distribution des pertes est conditionné par rapport à la valeur que  $\theta$  prend (i.e.  $f_{X|\Theta}$ ).

#### Définition 10.1.2 Distribution *a posteriori*



La distribution *a posteriori* nous permet de savoir avec quelle probabilité non-nulle notre paramètre  $\theta$  peut prendre une certaine valeur, sachant qu'on a observé certains  $x$ , qu'on dénote comme  $\pi_{\Theta|X}(\theta|x)$  :

$$\pi_{\Theta|X}(\theta|x) = \frac{f_{\Theta,X}(\theta, x)}{f_X(x)} = \frac{f_{X|\Theta}(x|\theta)\pi(\theta)}{\int f_{X|\Theta}(x|\theta)\pi(\theta)d\theta} \quad (10.1)$$

L'idée est de remplacer les différentes distributions dans l'Équation 10.1, et en déduire une distribution avec une paramétrisation différente<sup>a</sup>.

---

<sup>a</sup>. Souvent, la distribution *a posteriori* aura la même distribution que celle *a priori*, mais avec des paramètres différents.

**L'estimateur Bayésien** L'estimateur Bayésien est défini comme l'espérance du paramètre  $\theta$ , sachant la distribution de  $X$ . En d'autres mots, on veut l'espérance de la distribution *a posteriori* :

$$\hat{\theta}_{BAYES} = E[\Theta|X] \quad (10.2)$$

**Propriétés de l'estimateur** Voici quelques propriétés importantes de l'estimateur :

- ›  $\hat{\theta}_{BAYES}$  est biaisé (comparativement à l'estimateur MLE qui est non-biaisé) ;
- › Par contre, l'estimateur Bayésien a une plus petite variance que l'estimateur MLE. On sacrifie donc le Biais pour diminuer la variance de l'estimateur ;
- › **Remarque** : Si  $n$  est grand, il peut être préférable d'utiliser l'estimateur MLE.

### 10.1.1 Estimation par simulation

Une fois qu'on a développé et trouver la distribution *a posteriori* de  $\Theta|X$  (Équation 10.1), alors on peut facilement simuler l'estimateur Bayésien :

1.

#### Exemple 10.1.1 Exemple avec la Loi de Poisson



Soit  $X|\Lambda \sim Pois(\Lambda)$  et  $\Lambda \sim \Gamma(\alpha, \theta)$ . Alors, on a la distribution *a priori* suivante :

$$\Lambda \sim \pi(\lambda) = \frac{\lambda^{\alpha-1}}{\Gamma(\alpha)\theta^\alpha} e^{-\lambda/\theta}$$

Évidemment, on va s'attendre à ce que la distribution *a posteriori* obéisse à une loi Gamma aussi. On a (avec  $c(x)$  une constante) :

$$\begin{aligned} \pi_{\Lambda|X}(\lambda|x) &= c(x) \frac{\lambda^{\alpha-1} e^{-\lambda/\theta}}{\Gamma(\alpha)\theta^\alpha} \frac{\lambda^\alpha e^{-\lambda}}{x!} \\ &= k(x) \lambda^{x+\alpha-1} e^{-\lambda(\frac{1}{\theta} + 1)} \end{aligned}$$

avec  $c(x)$  et  $k(x)$  des constantes uniquement fonction de  $x$ .

On trouve donc que  $\pi_{\Lambda|X}(\lambda|x) \sim \Gamma\left(\alpha' = x + \alpha, \beta' = \left(\frac{1}{\theta} + 1\right)^{-1}\right)$   
 Puisque l'estimateur Bayésien est l'espérance de la distribution *a posteriori*, on a

$$\begin{aligned}\hat{\lambda}_{BAYES} &= E[\Lambda|X] \\ &= \int \lambda \cdot \pi_{\Lambda|X}(\lambda|x) d\lambda \\ &= \alpha' \beta' \\ &= (x + \alpha) \left( \frac{\theta}{1 + \theta} \right)\end{aligned}$$

### Exemple 10.1.2 Cas plus général ...



On a le modèle suivant pour  $X$ , tel que

$$f_{X_1, \dots, X_n|\Lambda}(x_1, \dots, x_n|\lambda) = \frac{\lambda^{x_1} e^{-\lambda}}{x_1!} \dots \frac{\lambda^{x_n} e^{-\lambda}}{x_n!}$$

Ainsi que la distribution *a priori* telle que

$$\Lambda \sim \pi(\lambda) = \frac{\lambda^{\alpha-1}}{\Gamma(\alpha)\theta^\alpha} e^{-\lambda/\theta}$$

Alors, la distribution *a posteriori* est donc

$$\begin{aligned}f_{\Lambda|X}(\lambda|x) &= c(x) \frac{\lambda^{\alpha-1}}{\Gamma(\alpha)\theta^\alpha} e^{-\lambda/\theta} \cdot \frac{\lambda^{x_1} e^{-\lambda}}{x_1!} \dots \frac{\lambda^{x_n} e^{-\lambda}}{x_n!} \\ &= k(x) \lambda^{\sum x_i + \alpha - 1} e^{-\lambda/\theta} e^{-n\lambda} \\ &= k(x) \lambda^{\sum x_i + \alpha - 1} e^{-\lambda(\frac{1}{\theta} + n)}\end{aligned}$$

On déduit donc que la distribution *a posteriori* obéit à une loi Gamma de paramètres  $\alpha' = \sum x_i + \alpha$  et  $\beta' = \left(\frac{1}{\theta} + n\right)^{-1} = \frac{\theta}{1+n\theta}$ . Alors, on

déduit facilement l'estimateur Bayésien :

$$\begin{aligned}
 \hat{\lambda}_{BAYES} &= \alpha' \beta' \\
 &= \frac{\theta (\sum_{i=1}^n x_i + \alpha)}{1 + n\theta} \\
 &= \frac{n\theta}{1 + n\theta} \left( \frac{\sum_{i=1}^n x_i}{n} \right) + \frac{1}{1 + n\theta} (\alpha\theta) \\
 &= \frac{n\theta}{1 + n\theta} \hat{\lambda}_{MLE} + \frac{1}{1 + n\theta} \underbrace{(\alpha\theta)}_{\text{Moy. distr. a priori}}
 \end{aligned}$$

**Remarque** On peut donc voir l'estimateur Bayésien comme une moyenne pondérée entre l'estimateur du maximum de vraisemblance et la moyenne de la distribution *a priori*. Lorsque  $n \rightarrow \infty$ , l'estimateur Bayésien sera semblable à l'EMV.

### Exemple 10.1.3 Exemple avec la loi Normale



On prend le modèle  $Y|\Theta = \frac{\sum_{i=1}^n x_i}{n} \sim N\left(\theta, \frac{\sigma^2}{n}\right)$ , avec  $\sigma^2$  connu. La densité *a priori* obéit aussi à une loi normale, telle que  $\Theta \sim N(\theta_0, \sigma_0^2)$ , où  $\theta_0, \sigma_0^2$  sont connus. On va donc s'attendre à avoir une distribution *a posteriori* qui va suivre une loi normale aussi. Alors, la distribution *a posteriori*  $\pi_{\Theta|X}(\theta|x)$  peut être trouvée :

$$\pi_{\Theta|X}(\theta|x) = c(y) e^{\frac{-(y-\theta)^2}{2(\sigma^2/n)}} e^{\frac{-(\theta-\theta_0)^2}{2\sigma_0^2}}$$

On va essayer de jumeler les 2 exposants des  $e$ , pour retrouver une certaine forme de la loi normale :

$$\frac{(y - \theta)^2}{2(\sigma^2/n)} + \frac{(\theta - \theta_0)^2}{2\sigma_0^2} = \frac{\sigma_0^2(y - \theta)^2 + \frac{\sigma^2}{n}(\theta - \theta_0)^2}{2\frac{\sigma^2}{n}\sigma_0^2}$$

Si on développe les termes séparément :

$$\sigma_0^2(y - \theta)^2 = \sigma_0^2(y^2 + \theta^2 - 2\theta y)$$

et

$$\frac{\sigma^2}{n}(\theta - \theta_0)^2 = \frac{\sigma^2}{n}(\theta^2 + \theta_0^2 - 2 \cdot \theta \cdot \theta_0)$$

Alors,

$$\sigma_0^2(y - \theta)^2 + \frac{\sigma^2}{n}(\theta - \theta_0)^2 = \left(\sigma_0^2 + \frac{\sigma^2}{n}\right) \theta^2 - 2 \left(y\sigma_0^2 + \theta_0 \frac{\sigma^2}{n}\right) \theta$$

Alors, la distribution *a posteriori* peut être ré-écrite comme

$$\pi_{\Theta|X}(\theta|x) = k(y) \exp \left\{ -\frac{1}{2} \left( \theta^2 - 2 \left( \frac{y\sigma_0^2 + \theta_0 \frac{\sigma^2}{n}}{\sigma_0^2 + \frac{\sigma^2}{n}} \right) \theta / \frac{\frac{\sigma^2}{n} \sigma_0^2}{\sigma_0^2 + \frac{\sigma^2}{n}} \right) \right\}$$

Si on manipule le numérateur, on trouve

$$\pi_{\Theta|X}(\theta|x) = k(y) \exp \left\{ -\frac{1}{2\gamma} \left( \theta - \frac{y\sigma_0^2 + \theta_0 \frac{\sigma^2}{n}}{\sigma_0^2 + \frac{\sigma^2}{n}} \right)^2 \right\}$$

Donc

$$\pi_{\Theta|X}(\theta|x) \sim N(\mu', \sigma' = \gamma)$$

où  $\mu' = \frac{y\sigma_0^2 + \theta_0 \frac{\sigma^2}{n}}{\sigma_0^2 + \frac{\sigma^2}{n}}$ . On peut aussi le ré-écrire (aussi appelé estimateur de crédibilité, sera vu en IARD2) :

$$\hat{\theta}_{BAYES} = \left( \frac{\sigma_0^2}{\sigma_0^2 + \frac{\sigma^2}{n}} \right) \bar{x} + \left( \frac{\sigma^2/n}{\sigma_0^2 + \frac{\sigma^2}{n}} \right) \theta_0$$

## 10.2 Exercices recommandés

Les exercices recommandés dans le *Loss Models*, 4<sup>th</sup> edition pour ce chapitre sont les suivants :

➤ 15.14 a 15.18, 15.21 a 15.27

## Troisième partie

### Annexes

# Annexe A

## Jeux de données du Loss Models

Voici les jeux de données qui sont utilisés dans le Loss Models, qui sont constamment utilisés dans les exercices du livre.

### A.1 Data set A

Table 11.1 Data Set A.	
Number of accidents	Number of drivers
0	81,714
1	11,306
2	1,618
3	250
4	40
5 or more	7



## A.2 Data set B

**Table 11.2** Data Set B.

27	82	115	126	155	161	243	294	340	384
457	680	855	877	974	1,193	1,340	1,884	2,558	15,743

## A.3 Data set C

**Table 11.3** Data Set C.

Payment range	Number of payments
0–7,500	99
7,500–17,500	42
17,500–32,500	29
32,500–67,500	28
67,500–125,000	17
125,000–300,000	9
Over 300,000	3

## A.4 Data set D1

**Table 11.4** Data Set D1.

Policyholder	Time of death	Time of surrender
1	–	0.1
2	4.8	0.5
3	–	0.8
4	0.8	3.9
5	3.1	1.8
6	–	1.8
7	–	2.1
8	–	2.5
9	–	2.8
10	2.9	4.6
11	2.9	4.6
12	–	3.9
13	4.0	–
14	–	4.0
15	–	4.1
16	4.8	–
17	–	4.8
18	–	4.8
19–30	–	–

## A.5 Data set D2

**Table 11.5** Data Set D2.

Policy	First observed	Last observed	Event <sup>a</sup>	Policy	First observed	Last observed	Event
1	0	0.1	s	16	0	4.8	d
2	0	0.5	s	17	0	4.8	s
3	0	0.8	s	18	0	4.8	s
4	0	0.8	d	19-30	0	5.0	e
5	0	1.8	s	31	0.3	5.0	e
6	0	1.8	s	32	0.7	5.0	e
7	0	2.1	s	33	1.0	4.1	d
8	0	2.5	s	34	1.8	3.1	d
9	0	2.8	s	35	2.1	3.9	s
10	0	2.9	d	36	2.9	5.0	e
11	0	2.9	d	37	2.9	4.8	s
12	0	3.9	s	38	3.2	4.0	d
13	0	4.0	d	39	3.4	5.0	e
14	0	4.0	s	40	3.9	5.0	e
15	0	4.1	s				

<sup>a</sup>“s” indicates surrender, “d” indicates death, “e” indicates expiration of the 5-year period.

# Annexe B

## Rappels mathématiques

### B.1 Algèbre linéaire

Soit la matrice  $\mathbf{A}$ , telle que

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

**Matrice transposée** la matrice transposée est définie par  $\mathbf{A}^\top$ , telle que

$$\mathbf{A}^\top = \begin{bmatrix} a & -c \\ -b & d \end{bmatrix}$$

**Déterminant d'une matrice** On peut calculer le déterminant  $\det(\mathbf{A})$  de la matrice  $\mathbf{A}$  tel que

$$\det(\mathbf{A}) = \begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$$

**Inverse d'une matrice** L'équivalent de l'opération  $\frac{1}{\mathbf{A}}$  en algèbre linéaire est de calculer la matrice inverse de  $\mathbf{A}^{-1}$ , telle que

$$\mathbf{A}^{-1} = \frac{1}{\det(\mathbf{A})} \begin{bmatrix} a & -c \\ -b & d \end{bmatrix}$$

où on multiplie par la matrice adjointe de  $\mathbf{A}$ . Il faut normalement calculer les cofacteurs, mais le cas à 2 dimensions est un cas simplifié.